Instituto Nacional de Estadística e Informática (INEI)
Programa de Extensión Universitaria en Ciencia de Datos (PEU-CD)

Exposición potencial a inundaciones asociadas a El Niño en Tumbes y Piura

Informe de avance del proyecto integrador

Equipo: Christopher, Maykol, Marcia y Luz Ángela

Corte del avance: 4 de noviembre de 2026

Repositorio: `github.com/marciashapiama/iapn-inei` · rama `auditoria-mvp-piloto`
Todas las cifras se reproducen con `python src/etl.py local` y se verifican con `python -m pytest`.

Índice

Resumen del avance **2**

1. Planteamiento **2**

2. Cronología del avance **3**

3. Arquitectura **3**

4. Auditoría: qué encontramos y qué corregimos **3**
4.1. Hallazgos principales 3
4.2. Cuánto cambiaron las cifras 5
4.3. Capa de radar reciente recalculada 5

5. Producto mínimo viable **5**

6. Calidad y pruebas **6**

7. Machine learning **7**

8. Aporte al INEI y políticas públicas **7**

9. Estado por componente **8**

10. Próximos pasos **8**

Resumen del avance

El proyecto busca cuantificar, **por distrito (UBIGEO)**, cuánta población, cuántas edificaciones, colegios y establecimientos de salud de Tumbes y Piura están **potencialmente expuestos** a inundaciones. Considera dos fuentes: escenarios de crecida de ríos con periodo de retorno de 10 y 100 años (JRC) y el agua detectada por el radar Sentinel-1 en 2017, 2023 y en los días recientes. Los resultados se publican en un tablero estático, reproducible y con trazabilidad de cada cifra.

En esta etapa:

1. **auditamos** el tablero que ya tenía el equipo y encontramos 17 problemas, entre ellos uno crítico: la población estaba desplazada unos 7,9 km;
2. **corregimos** las cifras y documentamos cuánto cambió cada una;
3. construimos un **producto mínimo viable** con ETL, metadatos, un mapa 2D sin GPU, un panel de decisiones y 38 pruebas automáticas;
4. **reprodujimos y evaluamos con rigor** el modelo de machine learning;
5. redactamos los documentos de aporte al INEI, estado del arte y políticas públicas.

Cuadro 1: Cifras principales tras las correcciones (zona inundable de 1 en 100 años, JRC). Exposición potencial, no personas afectadas.

Indicador	Valor	Definición
Superficie inundable	5 594 km²	incluye 1 731 km² del desierto de Sechura
Población potencialmente expuesta	408 970	WorldPop 2026 (modelada)
Edificaciones potencialmente expuestas	152 486	Google Open Buildings v3
Colegios dentro / hasta 1 km	684 / 2 636	OpenStreetMap
Establecimientos de salud dentro / hasta 1 km	146 / 577	RENIPRESS (SUSALUD)
Distritos con prioridad alta de revisión	15 de 76	índice relativo, no oficial

1. Planteamiento

Problema. No existe en un solo lugar una cuantificación territorial, reproducible y desagregada por distrito de la exposición a inundaciones en Tumbes y Piura que indique la procedencia y la incertidumbre de cada cifra.

Pregunta. ¿Cuánta población, cuántas edificaciones y qué servicios esenciales están potencialmente expuestos a inundación fluvial y a las inundaciones detectadas por radar? ¿Qué distritos deberían revisarse primero, considerando a la vez peligro, exposición y vulnerabilidad?

Objetivo general. Construir y validar un sistema reproducible de indicadores de exposición por UBIGEO, publicado como tablero estático con metadatos y pruebas.

Objetivos específicos.

1. Auditar el tablero existente y corregir los errores de cálculo y de rotulado.
2. Calcular la exposición por distrito, dentro de la mancha y en acumulados hasta 500 m y 1 km.
3. Documentar la fuente, la definición, la vigencia y el estado de cada capa.
4. Ofrecer un mapa usable sin aceleración gráfica y descargas abiertas.
5. Evaluar si el machine learning mejora una línea base simple.

6. Proponer un aporte estadístico al INEI y opciones de política pública.

Alcance. Piloto en Tumbes y Piura (76 distritos en los límites usados; 78 según el INEI). La extensión al resto del Perú queda para una fase posterior.

2. Cronología del avance

Fecha	Hito
3 nov. 2026	El equipo inicia el repositorio: monitor del mar (OISST), índices, economía, zonas de lluvia y caudal.
3 nov. 2026	Pestaña de inundaciones en 3D: peligro JRC, radar Sentinel-1 2017/2023 y días recientes; exposición de población, edificaciones, colegios y salud.
3–4 nov. 2026	Base distrito-semana (DesInventar, NASA POWER, GloFAS) y modelo de alerta con validación por años (42 commits en `main`).
4 nov. 2026	**Auditoría técnica y de datos** (17 hallazgos), corrección de cifras, MVP reproducible, pruebas, recálculo del radar reciente, documentos 01–05, informe final (Word) y este informe de avance (rama `auditoria-mvp-piloto`).

3. Arquitectura

El sistema no necesita servidor. GitHub Actions descarga y procesa los datos, y GitHub Pages publica archivos JSON/GeoJSON livianos. El costo de operación es cero.

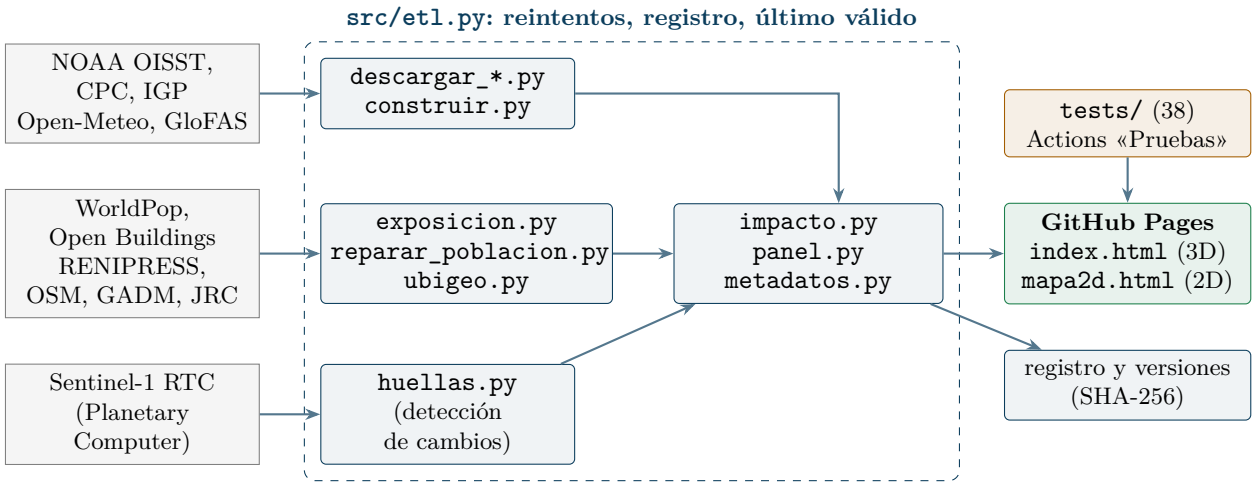


Figura 1: Flujo de datos. Cada paso deja registro en `data/registro/`. Si una fuente falla, se conserva el último resultado válido y se rotula como «rezagado».

4. Auditoría: qué encontramos y qué corregimos

4.1. Hallazgos principales

ID	Severidad	Problema	Corrección y evidencia
E1	Crítica	Población WorldPop desplazada 86 columnas (unos 7,9 km) al oeste: la ventana de recorte salía del borde del ráster de Perú.	Recorte corregido y archivo reparado; correlación con edificaciones de 0,00 a 0,80 (Fig. 2). Prueba automática de alineación.
E2	Alta	Colegios y salud: anillos disjuntos rotulados como acumulados («684 dentro, 1 268 a $\leq$ 500 m, 684 a $\leq$ 1 km»).	Claves explícitas de anillo y de acumulado; hasta 1 km hay 2 636 colegios.
E3	Alta	Piura + Tumbes $\neq$ total: faltaban 4 138 edificaciones fuera de los polígonos distritales.	Fila «Sin distrito asignado»; la suma concilia (prueba).
E4	Alta	Radar «últimos 24 días»: la referencia seca se solapaba con el evento.	Referencia que termina antes del evento; capa recalculada (Sección 4.3).
E5	Alta	El radar subdetecta la inundación urbana (Catacaos 2017: 1,1 km^2).	Advertencias; plan de validación independiente.
E6	Media	Sin mapa alternativo cuando falla WebGL.	`mapa2d.html` (Leaflet) y detección automática.
E7	Media	Se llamaba «viviendas» a huellas de edificación y se hablaba de «afectados».	Rótulo «edificaciones potencialmente expuestas».
E8–E17	Media/baja	Colegios de OSM con locales de Ecuador; 2 distritos ausentes en GADM; licencia GADM; publicación incompleta en Pages; probabilidades sin calibrar; nombres mal separados; otros.	Documentados en `docs/01_AUDITORIA_TECNICA_Y_DATOS.md`.

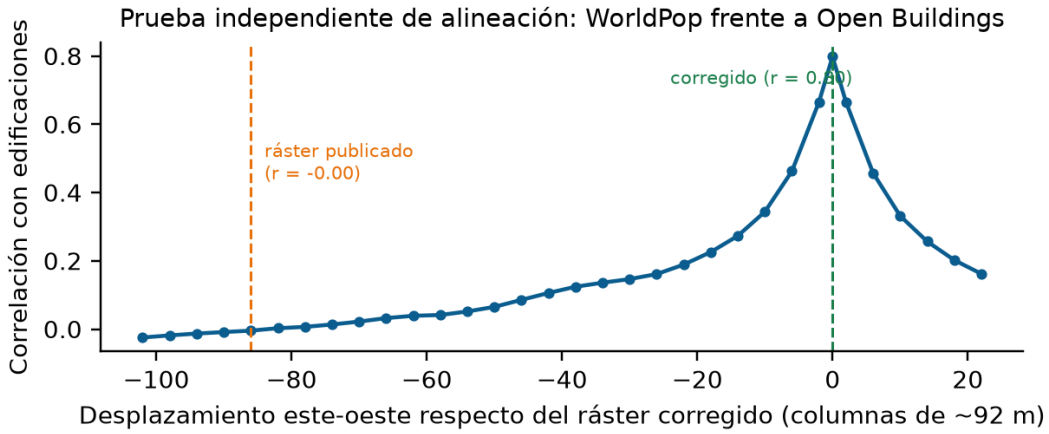


Figura 2: Prueba independiente de la corrección E1. La correlación entre la población WorldPop y la densidad de edificaciones de Open Buildings es máxima con el ráster corregido y prácticamente nula con el ráster publicado antes.

4.2. Cuánto cambiaron las cifras

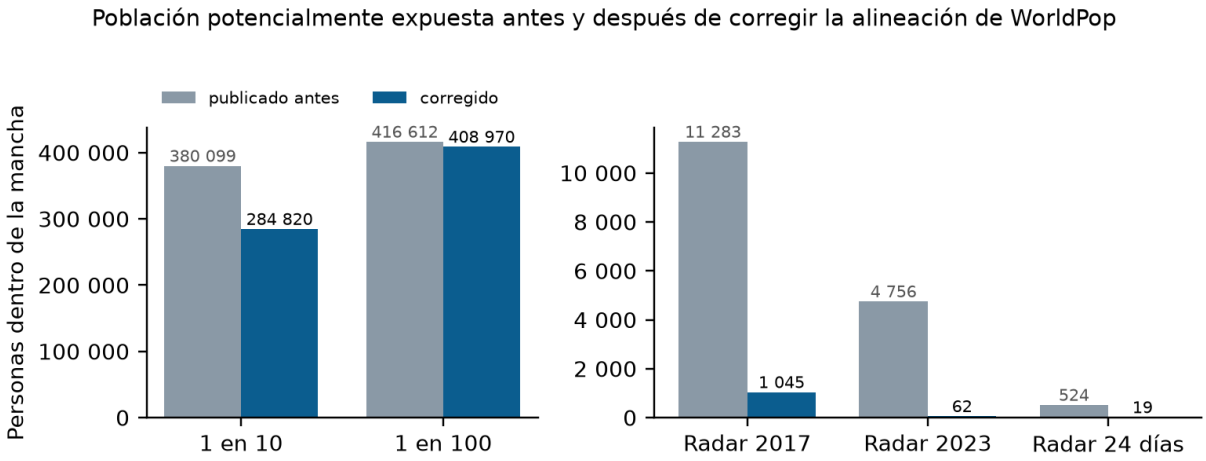


Figura 3: Población dentro de la mancha antes y después de la corrección E1. En 2023, la mancha (86 % en el desierto de Sechura) tenía en realidad 62 personas, no 4 756.

4.3. Capa de radar reciente recalculada

La capa de agua nueva de los últimos 24 días se recalculó con Sentinel-1 después de corregir el error E4. Usó una referencia seca del 1/8 al 10/10/2026 (42 pasadas) y un evento del 11/10 al 4/11/2026 (13 pasadas, del 12/10 al 2/11).

- **Detección:** 334,8 km² en bruto dentro de la caja de estudio; quedan **27,2 km²** en tierra de Tumbes y Piura después de aplicar las máscaras. El 77 % está en Sechura.
- **Exposición:** 24 personas y 8 edificaciones dentro de la mancha; ningún colegio ni establecimiento de salud dentro.
- **Umbral:** el umbral automático de Otsu, calculado como diagnóstico, fue −16,8 dB, muy cercano al umbral fijo de −17 dB.

Es temporada seca, así que el agua nueva corresponde sobre todo a riego y humedales, no a desbordes. La capa pasa el control de calidad y su estado es *vigente*.

5. Producto mínimo viable

- **ETL reproducible** (`src/etl.py`) con perfiles `local`, `diario` e `inundacion`. Hace descargas con reintentos y espera exponencial, registra cada corrida, guarda un manifiesto SHA-256 de versiones, escribe los archivos de forma atómica y se configura con variables de entorno.
- **Metadatos y estado por capa** (`metadatos.json`): fuente, licencia, definición, unidades, cobertura, resolución, versión, periodo, frecuencia, método, advertencias y estado (*vigente*, *rezagado*, *no disponible*, *estimado*). El estado se calcula con la fecha real del dato.
- **Cifras por UBIGEO** (`exposicion_distritos.csv`): dentro, anillos y acumulados hasta 500 m y 1 km, conciliadas con el total.
- **Mapa 2D accesible** sin GPU. Tiene selectores por departamento, provincia, distrito y ámbito de cuenca; escenarios 1/10 y 1/100 y radar 2017/2023/reciente; capas, leyenda, escala, comparador temporal con la fecha de cada pasada, ficha territorial y descargas CSV/GeoJSON. Funciona en celular.
- **Panel de decisiones**: peligro, exposición, vulnerabilidad y riesgo estimado en columnas separadas. El riesgo estimado es un índice relativo para priorizar revisiones, no una evaluación oficial (Fig. 4).

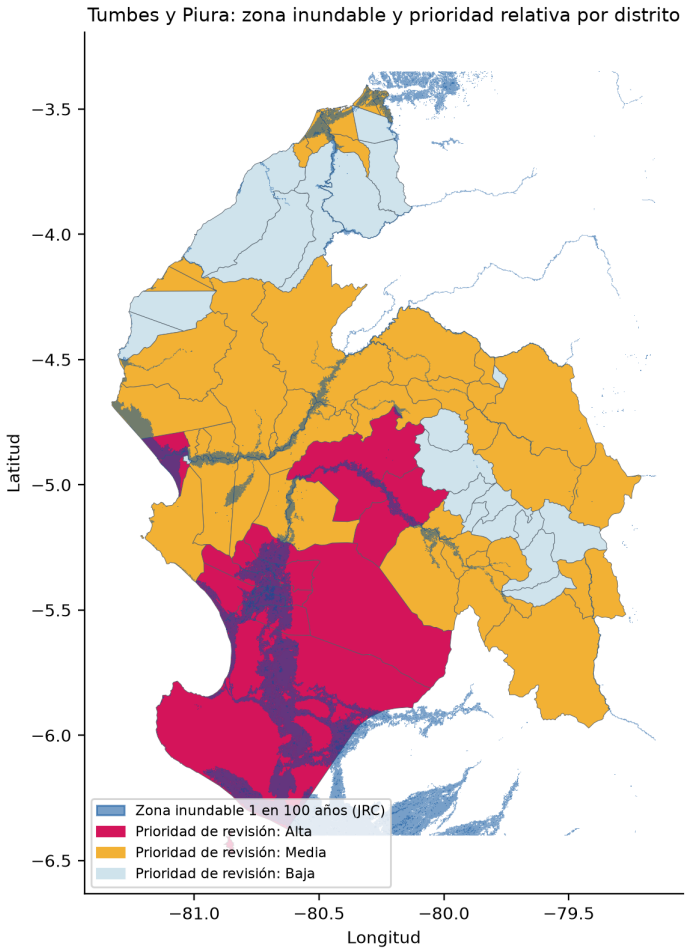


Figura 4: Zona inundable de 1 en 100 años (JRC) y prioridad relativa de revisión por distrito. La prioridad es el promedio de los percentiles de peligro, exposición y pobreza.

6. Calidad y pruebas

Hay 38 pruebas automáticas (`pytest`), todas aprobadas:

- **unitarias**: anillos y acumulados, umbral de Otsu, referencia del radar sin solape, reintentos, estados;
- **de integración y consistencia geoespacial**: sumas que concilian, acumulados que crecen, UBIGEO únicos, geometrías dentro de la caja, población alineada con las edificaciones, población distrital plausible, metadatos completos;
- **smoke test** del sitio.

En GitHub Actions, los flujos de actualización ejecutan las pruebas *antes* de guardar: si las cifras salen incoherentes, se conserva el último resultado válido. También probamos el recorrido de usuario en escritorio, en celular (375 px) y sin WebGL.

7. Machine learning

Cuadro 3: Decisión por caso de uso.

Caso	Decisión	Motivo
A. Susceptibilidad espacial	No entrenar aún	No hay etiquetas independientes; entrenar con el JRC o con el radar propio reproduciría su sesgo.
B. Clasificación SAR	No entrenar aún	Falta una referencia óptica o de campo. Otsu ya está implementado como diagnóstico.
C. Emergencia distrito-semana	Reproducido y evaluado	Hay etiquetas 2001–2015 (DesInventar/INDECI): 311 semanas positivas.

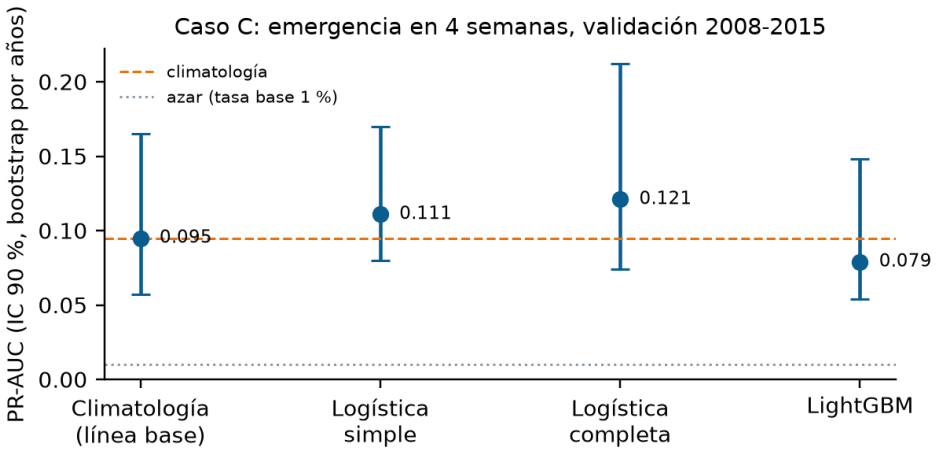


Figura 5: PR-AUC con intervalo de confianza del 90 % (bootstrap de 2 000 remuestreos por años completos). La logística simple supera a la climatología con probabilidad 0,92, pero el intervalo de la diferencia, $[-0{,}003;\ 0{,}039]$, incluye el cero.

Lectura.

- La mejora sobre la climatología es posible, pero no está demostrada.
- LightGBM no supera la línea base.
- Las probabilidades sin calibrar no deben leerse como probabilidades: el Brier es 0,144 sin recalibrar y 0,0095 con recalibración isotónica.
- El modelo captura el 46 % de las emergencias de Tumbes y solo el 5 % de las de Piura.
- No se justifica usar redes profundas con esta muestra.

8. Aporte al INEI y políticas públicas

Aporte. Proponemos una estadística territorial de población y edificaciones potencialmente expuestas por UBIGEO, con metadatos, diccionario de variables, periodicidad y gobernanza. Puede interoperar con CENEPRED, MINEDU, MINSA, ANA y SENAMHI. El INEI produce estadística; las alertas y las obras corresponden a otras entidades.

Políticas para evaluar.

1. Continuidad educativa en los locales expuestos.
2. Continuidad de los servicios de salud.

3. Ordenamiento territorial.
4. Mantenimiento focalizado de drenes y cauces.
5. Rutas de evacuación y refugios.
6. Comunicación de riesgo.
7. Levantamiento prioritario de datos.

Ninguna reemplaza una evaluación oficial de riesgo ni autoriza reubicaciones.

9. Estado por componente

Componente	Estado	Evidencia / nota
Auditoría técnica y de datos	**Hecho**	`docs/01`, `auditoria_cifras.json`
Corrección de cifras (E1–E4, E7)	**Hecho**	`cifras_antes_despues.csv`; pruebas
Radar reciente recalculado	**Hecho**	`data/huellas/vivo.json`
ETL con reintentos, registro y degradación	**Hecho** / **Parcial**	local probado; perfiles en línea dependen de Actions
Metadatos y estado por capa	**Hecho**	`metadatos.json`
Mapa 2D, selectores, comparador y descargas	**Hecho**	recorrido en escritorio y celular
Panel de decisiones por UBIGEO	**Hecho**	`panel_distritos.csv`
Validación con cifras oficiales del INEI	**Parcial**	se usó una estimación 2020 de terceros
Umbral SAR adaptativo	**Parcial**	implementado; falta una referencia para elegirlo
Pruebas y CI	**Hecho**	38 aprobadas
Machine learning (plan y experimento)	**Hecho**	`docs/02`, `ml_evaluacion.json`
Aporte al INEI, bibliografía, políticas	**Hecho**	`docs/03-05` (21 referencias verificadas)
Informe final en Word	**Hecho**	`INFORME_FINAL_PROYECTO_INTEGRADOR.docx`
Publicación en GitHub Pages	**Parcial**	rama subida; falta fusionar a `main`

10. Próximos pasos

1. **P0**: fusionar la rama en `main` para publicar el tablero corregido.
2. **P1**: obtener los límites distritales oficiales del INEI (78 distritos), el padrón ESCALE de colegios y la población oficial por distrito para validar.
3. **P2**: construir una referencia independiente de inundación para 2017 y 2023, y entrenar y validar los casos A y B por cuenca y por evento.
4. **P3**: extender el sistema a la costa norte y luego a todo el país.

Referencias

[1] Breña-Aliaga, J. C., & Cruz-Machacuay, J. (2026). Estimación de umbrales y dinámica de inundaciones integrando Random Forest, el índice SDWI de Sentinel-1, el modelo HAND y datos SAR en la cuenca del río Tumbes. *Ingeniería del Agua, 30*(3), 211–228. `https://doi.org/10.4995/ia.25917`

[2] Breña Aliaga, J. C., Vidal, J., Felipe, O., Bourrel, L., Rau, P., & Lavado-Casimiro, W. (2026). Estimation of flood thresholds for hydrological warning purposes using Sentinel-1 SAR imagery-based modeling in the Tumbes River basin (Peru). *Remote Sensing, 18*(10), 1493. https://doi.org/10.3390/rs18101493

[3] Twele, A., Cao, W., Plank, S., & Martinis, S. (2016). Sentinel-1-based flood mapping: A fully automated processing chain. *International Journal of Remote Sensing, 37*(13), 2990–3004. https://doi.org/10.1080/01431161.2016.1192304

[4] Tellman, B., Sullivan, J. A., Kuhn, C., Kettner, A. J., Doyle, C. S., Brakenridge, G. R., Erickson, T. A., & Slayback, D. A. (2021). Satellite imaging reveals increased proportion of population exposed to floods. *Nature, 596*(7870), 80–86. https://doi.org/10.1038/s41586-021-03695-w

[5] Chini, M., Hostache, R., Giustarini, L., & Matgen, P. (2017). A hierarchical split-based approach for parametric thresholding of SAR images. *IEEE Transactions on Geoscience and Remote Sensing, 55*(12), 6975–6988. https://doi.org/10.1109/TGRS.2017.2737664

[6] Dottori, F., Salamon, P., Bianchi, A., Alfieri, L., Hirpa, F. A., & Feyen, L. (2016). Development and evaluation of a framework for global flood hazard mapping. *Advances in Water Resources, 94*, 87–102. https://doi.org/10.1016/j.advwatres.2016.05.002

[7] Tatem, A. J. (2017). WorldPop, open data for spatial demography. *Scientific Data, 4*, 170004. https://doi.org/10.1038/sdata.2017.4

[8] Nearing, G., et al. (2024). Global prediction of extreme floods in ungauged watersheds. *Nature, 627*(8004), 559–563. https://doi.org/10.1038/s41586-024-07145-1

[9] Roberts, D. R., et al. (2017). Cross-validation strategies for data with temporal, spatial, hierarchical, or phylogenetic structure. *Ecography, 40*(8), 913–929. https://doi.org/10.1111/ecog.02881

[10] Dawson, G., Butt, J., Jones, A., & Fraccaro, P. (2023). Flood susceptibility mapping at the country scale using machine learning approaches. *Applied AI Letters, 4*(4), e88. https://doi.org/10.1002/ail2.88

La bibliografía completa (21 referencias en APA 7, con los DOI verificados en Crossref) está en `docs/04_ESTADO_DEL_ARTE_Y`