PROYECTO INTEGRADOR · PEU-CD INEI

¿Cómo funciona nuestro modelo de emergencias por inundación?

Guía didáctica, variable por variable, del modelo que estima la probabilidad de una emergencia por inundación o lluvias en los distritos de Tumbes y Piura en las próximas 1 a 4 semanas.

Marcia · Christopher · Maykol · Luz Ángela

5 de noviembre de 2026 · versión 2: variable dependiente del SINPAD (INDECI)

Parte	Pregunta que responde
1	¿Qué queremos hacer y por qué no usamos el satélite para predecir?
2	¿Cuál es la unidad de análisis?
3	¿Qué es la variable dependiente Y? ¿Cuándo vale 1 y cuándo 0?
4	¿Cómo se distribuye Y en el tiempo y entre distritos?
5	¿Qué variables independientes usamos y por qué cada una?
6	¿Cuál es la fórmula del modelo? Un ejemplo con números reales
7	¿Cómo se estiman los coeficientes (el «sujeto a»)?
8	¿Por qué una regresión logística y no otro modelo?
9	¿Cómo sabemos si predice? Validación y resultados
10	Limitaciones, próximos pasos y preguntas probables del profesor

PARTE 1

La idea en una frase

Estimar, para cada distrito y cada semana, la probabilidad de que en las próximas 1 a 4 semanas se registre una emergencia por inundación o lluvias.

El objetivo es **anticipar**: con lo que sabemos hoy (cuánto ha llovido, cómo viene el río, qué tan caliente está el mar, cuántas emergencias suele tener el distrito y en qué época del año estamos), decir qué distritos tienen más riesgo en el próximo mes.

¿Por qué no usamos el satélite para predecir? Por dos razones que comprobamos con 13 inundaciones reportadas en noticias:

Problema	Qué pasa	Evidencia
Rezago	Sentinel-1 da la vuelta a la Tierra y vuelve a pasar por el mismo lugar cada varios días. Cuando pasa, el agua de una inundación corta ya bajó.	Piura ciudad 2017: el satélite pasó 5 días después y solo vio 0,03 km² de agua.
Ciudad	Paredes, techos y pistas rebotan la señal del radar y esconden el agua entre edificios.	Calles inundadas por lluvia (Piura, Tumbes, Chulucanas, Máncora): 0 de 4 detectadas.

En simple

El satélite sirve para **confirmar** inundaciones grandes en el llano después de que pasan. Para **anticipar** usamos variables de clima y ríos que se miden todas las semanas. Ninguna variable del modelo sale del satélite.

PARTE 2

La unidad de análisis: un distrito en una semana

La base de datos tiene **una fila por cada distrito y cada semana** (de lunes a domingo). Son 76 distritos de Tumbes y Piura, semana a semana de enero de 2003 a diciembre de 2025. Así se ven tres filas reales:

Distrito	Semana	Lluvia 30 días	Razón de caudal	Niño 1+2	¿Registro esa semana?	Y
Zarumilla	2 ene 2023	8,9 mm	0,46	−0,8 °C	no	0
Zarumilla	16 ene 2023	20,4 mm	0,92	−0,3 °C	no	1
Zarumilla	6 feb 2023	23,5 mm	0,77	0,7 °C	sí	1

En simple

Cada fila es una «foto» del distrito en una semana: lo que se sabe hasta ese momento (las X) y lo que pasó después (la Y). El modelo aprende comparando miles de fotos.

¿Por qué semanas y no días? Como conversamos con el profesor: los reportes de INDECI son diarios, pero a nivel diario hay mucho ruido (un evento puede registrarse un día u otro). Agrupar por semanas da una señal más estable y un aviso con días de anticipación es más útil.

PARTE 3

La variable dependiente (Y): cuándo vale 1 y cuándo vale 0

Es lo que queremos predecir. En el código se llama **emergencia_1a4**. Se construye en tres pasos.

Paso 1. La fuente. El **SINPAD** (Sistema de Información Nacional para la Respuesta y Rehabilitación) es el registro oficial de emergencias del INDECI. Se publica en la Plataforma Nacional de Datos Abiertos como «Emergencias y daños a nivel nacional por departamento» (licencia ODC-By). Cada registro es **una emergencia con código, fecha y UBIGEO**. De 151 491 registros del Perú, 8 556 son de Tumbes y Piura. Usamos solo los de agua, de 2003 a 2025:

Peligro en el SINPAD (Tumbes y Piura, 2003–2025)	Registros	¿Entra en Y?
Lluvia intensa	2 844	Sí
Inundación	218	Sí
Total en Y	3 062	
Incendios urbanos e industriales	2 564	No
Vientos fuertes	1 601	No
Sismo	107	No
Marejada	39	No: es oleaje del mar
Huayco	14	No

La descarga queda trazada: URL, fecha y huella SHA-256 de cada archivo, y el conteo de registros después de cada filtro (data/modelo/sinpad/procedencia.json). Cada registro conserva su código SINPAD.

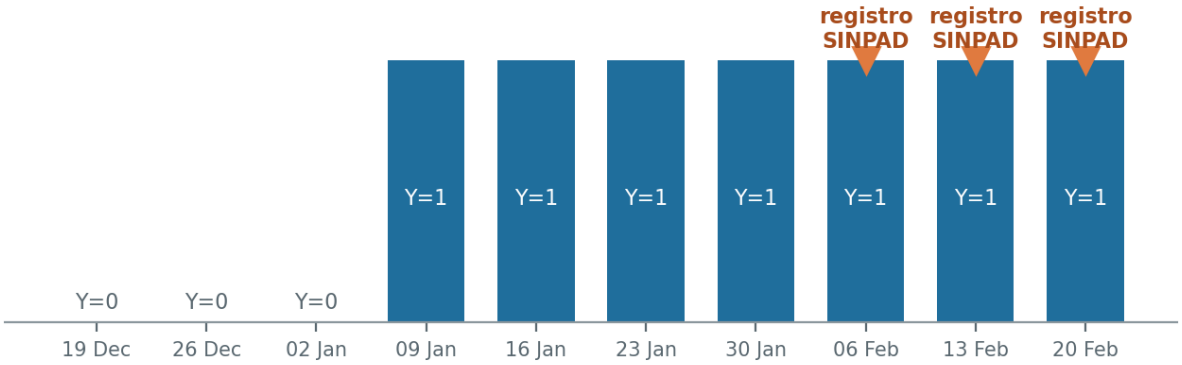
Paso 2. La semana del evento. Para cada distrito d y semana t:

$$E(d, t) = 1 \text{ si hay al menos un registro en el distrito } d \text{ durante la semana } t\text{; si no, } 0$$

Paso 3. Mirar hacia adelante. La variable dependiente pregunta si habrá un registro en el próximo mes:

$$Y(d, t) = 1 \text{ si } E(d, t+1) + E(d, t+2) + E(d, t+3) + E(d, t+4) \geq 1$$
$$Y(d, t) = 0 \text{ en otro caso}$$

Zarumilla, ciclón Yaku (dic 2022 a feb 2023): cada barra es una semana



Ejemplo real con el ciclón Yaku. El primer registro SINPAD en Zarumilla fue el 6 de febrero de 2023: las cuatro semanas anteriores (9 al 30 de enero) tienen Y = 1. El 2 de enero el registro queda a 5 semanas, así que Y = 0. Siguieron registros el 13 y el 20 de febrero.

En simple

Y = 1 marca las semanas en que el modelo **debería haber avisado**. Por eso el modelo aprende cómo se veían la lluvia y el río en las semanas previas a una emergencia.

La pregunta clave del profesor

El profesor preguntó: «¿cuándo es 0? ¿quién avisa que ya no llueve?». La respuesta es que **Y no es un estado** («el distrito está inundado» o «está en emergencia»). **Y es la aparición de un registro nuevo.** Vale 0 cuando en las próximas 4 semanas no aparece ningún registro. No necesitamos saber cuándo termina la emergencia ni cuándo el COEN la levanta.

Si se quisiera modelar el estado, habría que usar otra fuente: las declaratorias de estado de emergencia (decretos supremos), que tienen fecha de inicio y de fin. Es una pregunta distinta.

Sujeto a (condiciones de Y):

Condición	Por qué
Y solo toma los valores 0 o 1	Es una variable binaria: hubo o no hubo registro.
Y se calcula de enero de 2003 a diciembre de 2025	El archivo 2026 solo cubre enero a junio y trae errores (viviendas destruidas repite el número de afectados).
La fecha debe coincidir con las columnas AÑO y MES	El archivo mezcla DD/MM/AAAA y MM/DD/AA; se comprobó en los 3 363 registros de agua (0 descartados).
Las 4 últimas semanas con dato quedan sin Y	Todavía no se sabe qué pasó en sus 4 semanas siguientes.
Un distrito sin registros tiene Y = 0	Supuesto: si no se reportó, no hubo emergencia (puede haber subregistro).

Por qué cambiamos de fuente

La primera versión usaba **DesInventar**, que termina en 2015, mezclaba marejadas y en años antiguos recogía prensa. Comparado con el SINPAD en 2003–2015, solo 37 de 118 semanas con registro coinciden. Por eso se usa **solo el SINPAD** para todo el periodo: no se mezclan fuentes. Además, los 6 eventos de 2017 y 2023 verificados con noticias tienen registro SINPAD en el mismo distrito a menos de 14 días.

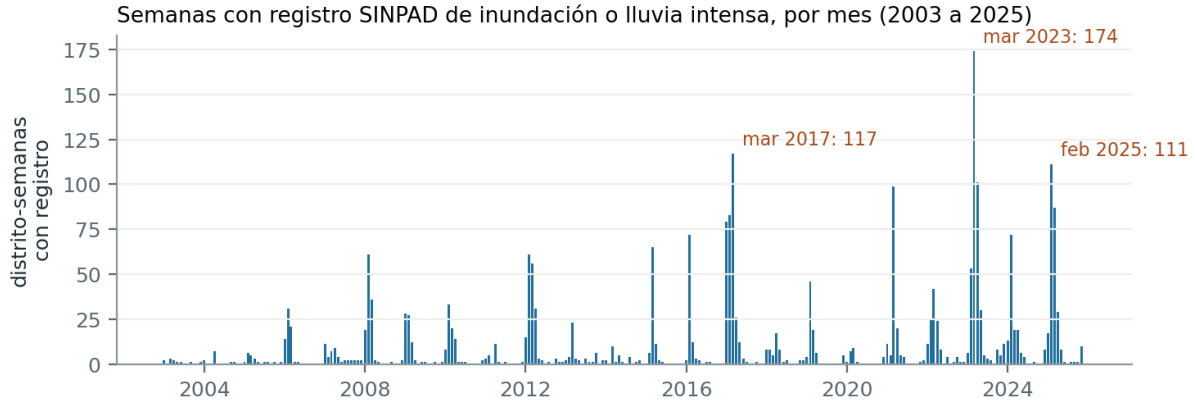
PARTE 4

La distribución de Y

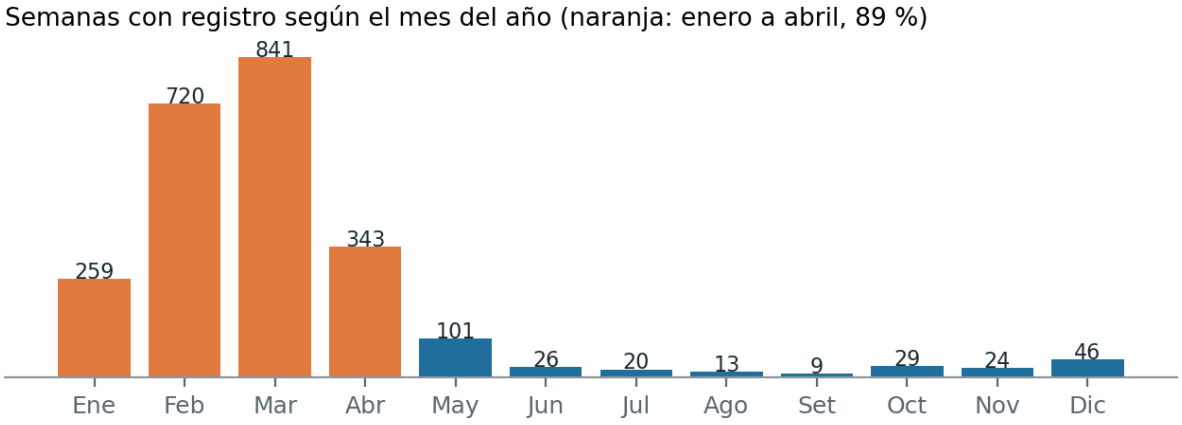
Lo que el profesor pidió ver: cuántos 1 y cuántos 0 hay, en el tiempo y por distrito.

Indicador (enero 2003 a diciembre 2025)	Valor
Filas distrito-semana con Y definida	90 896
Registros SINPAD de agua	3 062
Distrito-semanas con al menos un registro (E = 1)	2 431 (2,7 %)
Filas con Y = 1	7 173 (7,9 %)
Filas con Y = 0	83 723 (92,1 %)
Distritos sin ningún registro	0 de 76
Semanas con registro en Piura / Tumbes	1 770 / 661

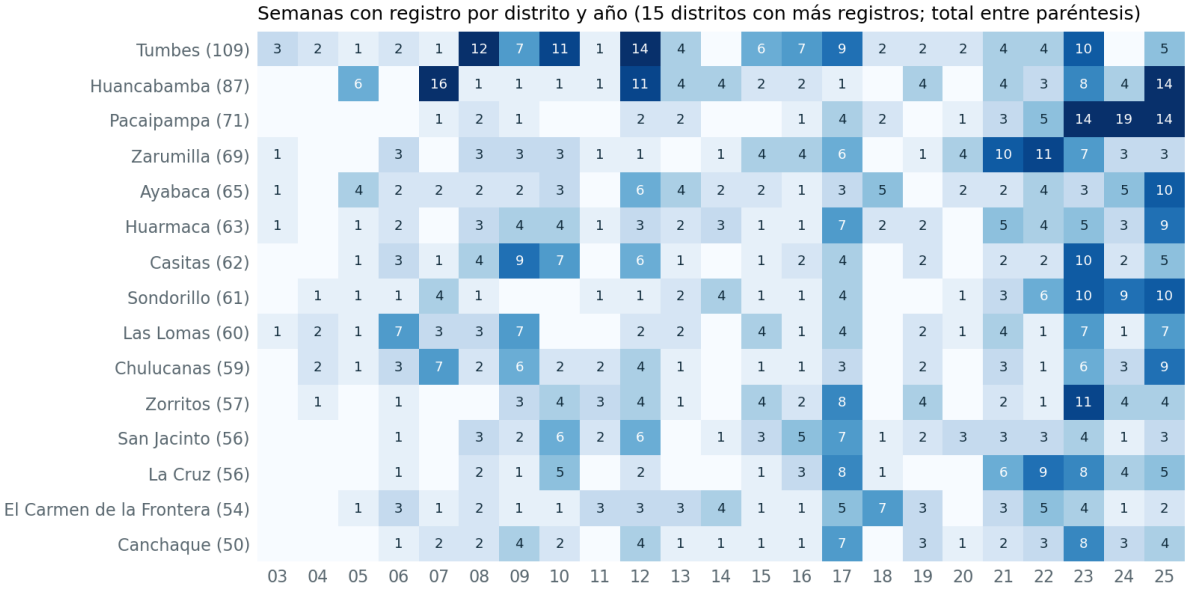
Y = 1 es unas tres veces E = 1 porque cada registro «enciende» las cuatro semanas anteriores.



Los picos son los años de El Niño costero (2017), el ciclón Yaku (2023) y 2025. Con DesInventar estos años no existían en la variable dependiente.



El 89 % de las semanas con registro cae entre enero y abril, la temporada de lluvias.



Por distrito. Tumbes sigue primero (109 semanas), pero ahora aparecen muchos distritos de la sierra de Piura (Huancabamba, Pacaipampa, Ayabaca, Huarmaca), donde la lluvia intensa daña viviendas y caminos. Las columnas de 2017 y 2023 son las más oscuras.

En simple

Y es un evento **poco frecuente** (8 de cada 100 filas), **estacional** (enero a abril) y **repartido** entre costa y sierra. Estas características deciden qué modelo se puede usar.

PARTE 5

Las variables independientes (X), una por una

Todas usan solo información disponible hasta la semana t: así el modelo no «hace trampa» mirando el futuro. Están en cuatro grupos.

Grupo A · Lluvia (fuente: NASA POWER, punto central del distrito, celdas de ~50 km)

Variable	Qué mide y cómo se calcula	Por qué entra al modelo
lluvia_7d	Lluvia acumulada en la semana (mm).	Una lluvia fuerte reciente activa quebradas y anega calles.
lluvia_30d	Suma de las últimas 4 semanas (mm).	Un suelo ya mojado no absorbe: la siguiente lluvia escurre.
lluvia_90d	Suma de las últimas 13 semanas (mm).	Detecta una temporada húmeda larga, típica de El Niño.
lluvia_7d_anom, _30d_anom, _90d_anom	Cada lluvia menos su promedio 2001–2020 para esa misma semana del año.	50 mm es normal en marzo y extraordinario en agosto; la anomalía lo distingue.
lluvia_7d_prev	Lluvia de la semana anterior (mm).	El daño suele llegar con días de retraso.

Grupo B · Ríos (fuente: GloFAS v4 vía Open-Meteo)

Variable	Qué mide y cómo se calcula	Por qué entra al modelo
caudal	Caudal semanal del río más cercano al distrito: Tumbes, Chira o Piura (m^3/s).	Los desbordes vienen del río, que junta la lluvia de la sierra.
caudal_razon	Caudal dividido entre su mediana 2001–2020 para esa semana. 1 = normal, 3 = el triple.	Pone a ríos grandes y chicos en la misma escala.
caudal_max_4s	El caudal más alto de las últimas 4 semanas (m^3/s).	Un pico reciente indica un río cargado.

Grupo C · Mar y El Niño (fuente: NOAA CPC, semanal)

Variable	Qué mide y cómo se calcula	Por qué entra al modelo
nino12	Anomalía de la temperatura del mar frente a Perú y Ecuador, región Niño 1+2 (°C).	Es la señal de El Niño costero: el mar caliente trae lluvias intensas al norte.
nino34	Anomalía en el Pacífico central, región Niño 3.4 (°C).	Es la señal de El Niño global.

Grupo D · El distrito: exposición, historia y época

Variable	Qué mide y cómo se calcula	Por qué entra al modelo
km2_inundable_rp10, _rp100	Área del distrito dentro de la zona inundable de 1 en 10 y 1 en 100 años (km², JRC).	Distritos con más llanura inundable tienen más donde inundarse.
viviendas_rp10, _rp100	Edificaciones dentro de esa zona (Google Open Buildings).	Más edificios expuestos, más probable que una inundación cause una emergencia.
personas_rp100	Personas dentro de la zona de 1 en 100 años (WorldPop).	Lo mismo, contado en personas.
frecuencia_historica	Proporción de semanas con registro del distrito, calculada **solo con los años de entrenamiento**.	Algunos distritos se inundan siempre: es la «memoria» del lugar.
sen_semana, cos_semana	sen(2π·s/52) y cos(2π·s/52), con s = semana del año.	Ubican la semana en el calendario sin un corte en Año Nuevo (la semana 52 queda junto a la 1).

En simple

Hay variables que **cambian cada semana** (lluvia, ríos, mar): son las que deberían avisar que se viene algo. Y hay variables que **describen al distrito** (exposición, historia, época): dicen dónde y cuándo suele pasar. El modelo completo usa las 20; el principal usa solo 6.

Ojo

La exposición es de 2026 y se usa también en semanas de 2003 a 2025. No es información del futuro sobre la emergencia, pero es un anacronismo. El modelo principal no usa esas columnas.

PARTE 6

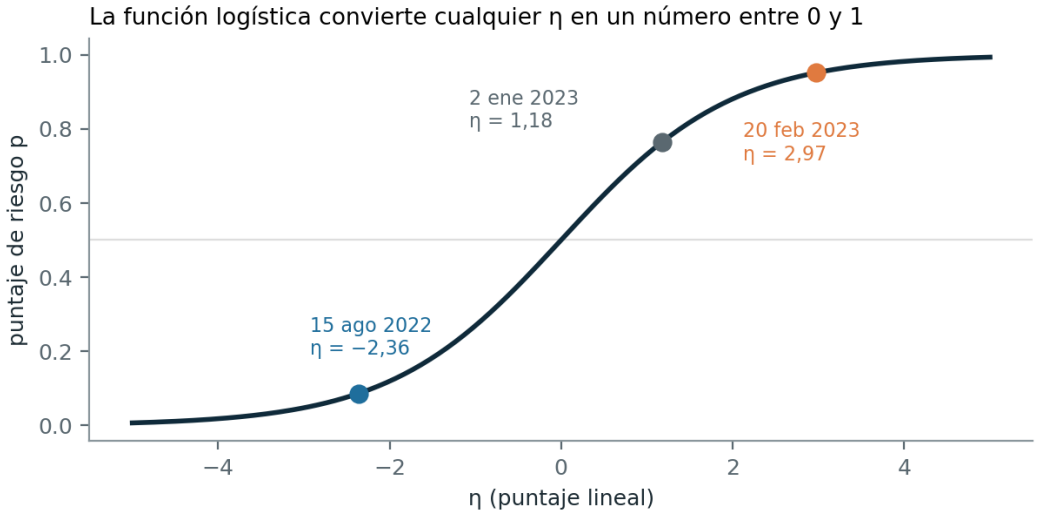
La fórmula del modelo principal

Es una **regresión logística** con 6 variables.

$$P(Y = 1 \mid X) = 1 / (1 + e^{-\eta})$$

$$\eta = \beta_0 + \beta_1 \cdot \log(1 + \text{lluvia_30d}) + \beta_2 \cdot \log(\text{caudal_razon}) + \beta_3 \cdot \text{nino12} + \beta_4 \cdot \text{frecuencia_historica} + \beta_5 \cdot \text{sen_semana} + \beta_6 \cdot \text{cos_semana}$$

Símbolo	Qué es	En palabras
$P(Y = 1 \mid X)$	Probabilidad de que Y valga 1 dados los valores de X	El riesgo de emergencia en el próximo mes.
η (eta)	Combinación lineal de las variables	Un puntaje: más alto, más riesgo.
β_0	Intercepto	El riesgo de base cuando todas las variables están en su promedio.
$\beta_1 \ldots \beta_6$	Coeficientes	Cuánto sube η cuando la variable sube una desviación estándar.
log( )	Logaritmo natural	Suaviza los valores extremos de lluvia y caudal. El +1 evita log(0); la razón de caudal se acota en 0,05 antes del log.
e	≈ 2,718	La base del logaritmo natural.



La curva logística. Los tres puntos son semanas reales de Zarumilla calculadas con el modelo final.

Ejemplo con números reales (modelo final entrenado con 2003–2025)

Con $\beta_0 = -1{,}476$ y las variables estandarizadas (z), el modelo da:

Semana (Zarumilla)	Lluvia 30 d	Razón caudal	Niño 1+2	η	p	Índice	Y real
15 ago 2022 (época seca)	23,7 mm	1,52	−0,8	−2,36	0,09	38	0
2 ene 2023 (inicio lluvias)	8,9 mm	0,46	−0,8	1,18	0,76	88	0
20 feb 2023 (Yaku)	67,8 mm	1,59	0,4	2,97	0,95	99	1

Lo que enseña este ejemplo

El 2 de enero, con poca lluvia y el río bajo, el puntaje ya es 0,76 solo por la **época del año**. El 20 de febrero, con 68 mm en el mes, el río por encima de lo normal y el mar más caliente, sube a 0,95. Con la Y del SINPAD la lluvia y el mar **sí mueven** el puntaje, pero la estación sigue pesando mucho.

¿Por qué p no es una probabilidad real?

El p de 0,95 **no** significa «95 % de probabilidad». El modelo se entrena con pesos que inflan los casos raros, así que p es un puntaje para ordenar, no una probabilidad calibrada. Por eso el tablero muestra un **índice de 0 a 100**: el porcentaje de distrito-semanas de la historia con un puntaje menor. 99 = está en el 1 % más alto de la historia.

PARTE 7

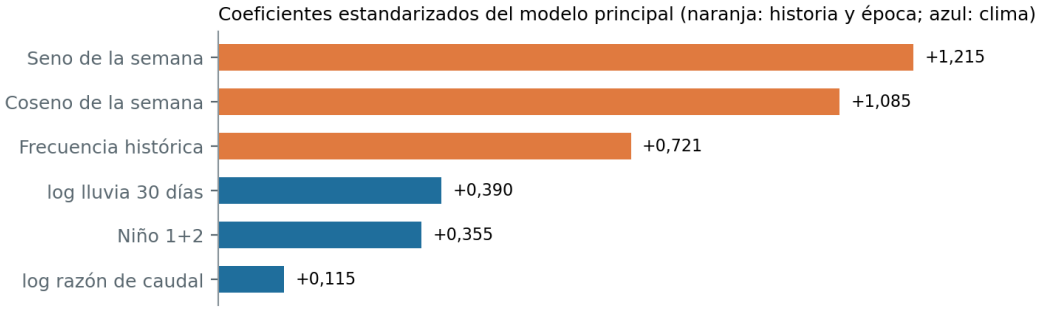
Cómo se estiman los β: el «sujeto a»

Los coeficientes no se eligen a mano: el modelo los aprende de los datos de entrenamiento resolviendo este problema.

$$\min_{\beta} \tfrac{1}{2}\|\beta\|^2 + C \cdot \Sigma_i\, w_i \cdot \ell(y_i, p_i) \text{ con } C = 0{,}3$$

Pieza	Qué es	Para qué sirve
$\ell(y, p)$	Pérdida logarítmica: $-[y \cdot \log p + (1-y) \cdot \log(1-p)]$	Castiga equivocarse con seguridad: decir p = 0,01 cuando sí hubo emergencia cuesta mucho.
w_i	Peso de cada fila: n / (2 · n de su clase)	Como Y = 1 es el 7,9 %, cada semana con emergencia pesa como unas 12 sin emergencia. Si no, el modelo tendería a decir siempre «no».
$\frac{1}{2}\|\beta\|^2$	Penalización L2 (regularización)	Impide que los β crezcan demasiado; reduce el sobreajuste con pocos datos.
C = 0,3	Intensidad de la penalización	Mientras más chico C, más fuerte la penalización.

Antes de estimar, cada variable se **estandariza**: z = (x − media) / desviación estándar, usando solo los datos de entrenamiento. Así los β se pueden comparar entre sí. Los datos faltantes se reemplazan por la mediana del entrenamiento.



Coeficientes del modelo final (dashboard/data/riesgo.json).

Coeficiente	Valor	Cómo se lee
Seno y coseno de la semana	+1,215 y +1,085	Juntos marcan el pico de riesgo en la temporada de lluvias (enero a abril). Es lo que más pesa.
Frecuencia histórica	+0,721	Un distrito con más emergencias pasadas tiene más riesgo.
log lluvia 30 días	+0,390	Más lluvia en el último mes, más riesgo. Con DesInventar era solo +0,024.
Niño 1+2	+0,355	Mar más caliente frente a la costa, más riesgo. Antes era +0,039.
log razón de caudal	+0,115	Río por encima de lo normal, más riesgo, efecto chico.

En simple

Todos los signos son positivos, como esperábamos. Con la Y oficial, **la lluvia y el mar ya pesan** (entre 9 y 16 veces más que antes), aunque la época del año sigue pesando unas 3 veces más que la lluvia. El modelo sabe bien **cuándo** y **dónde** suele haber emergencias y ahora reacciona más a **cuánto** está lloviendo.

PARTE 8

¿Por qué una regresión logística?

Razón	Explicación
Y es binaria	La logística está hecha para variables 0/1 y entrega un número entre 0 y 1.
Es interpretable	Cada β tiene un signo y un tamaño que se pueden explicar a una autoridad.
Es estable	Con 2 431 semanas con registro y 6 variables hay muchos eventos por variable; los coeficientes no cambian de signo entre años.
Se puede corregir el desbalance	Los pesos w_i evitan que ignore los casos raros.

Comparamos con otros modelos usando los mismos datos y las mismas reglas

Modelo	Qué hace	PR-AUC	ROC-AUC	Veredicto
Climatología	Solo mira la frecuencia del distrito en ese mes. Es la referencia.	0,397	0,865	La mejor en PR-AUC
Logística simple	6 variables. Modelo principal.	0,372	0,875	Mejor ROC-AUC; interpretable
Logística completa	Las 20 variables.	0,385	0,867	No mejora con claridad a la simple
LightGBM	200 árboles pequeños, muy regularizados.	0,396	0,869	Empata con la climatología

Validación año por año 2008–2025 con la Y del SINPAD. Con DesInventar (2008–2015) los valores eran 0,095, 0,114, 0,122 y 0,082, pero no se comparan directamente: la tasa base cambió de 1 % a 9 %.

Modelos que no son viables con estos datos

Redes neuronales (LSTM, GRU) o random forest profundos necesitan muchos más eventos y variables con más detalle. Con la lluvia en celdas de ~50 km memorizarían ruido. LightGBM, ya bastante flexible, solo empata con la referencia.

Modelos que sí podrían estimar mejor (propuesta)

Modelo	Qué mejora	Viabilidad
Logística multinivel (efecto aleatorio por distrito)	Los datos son un panel: le da a cada distrito su propio nivel de riesgo base y reemplaza a la frecuencia histórica de forma más rigurosa.	Alta. Recomendado como siguiente paso.
Logística para eventos raros (Firth o King-Zeng)	Corrige el sesgo de la logística cuando hay muy pocos Y = 1.	Alta. Cambio pequeño en el código.
Riesgo en tiempo discreto (enlace cloglog)	Modela el tiempo hasta la siguiente emergencia: encaja con la idea de «1 a 4 semanas».	Media.
Regresión de Poisson o binomial negativa	Predice cuántos eventos habrá en lugar de si habrá alguno.	Media; hoy casi siempre hay 0 o 1.

En simple

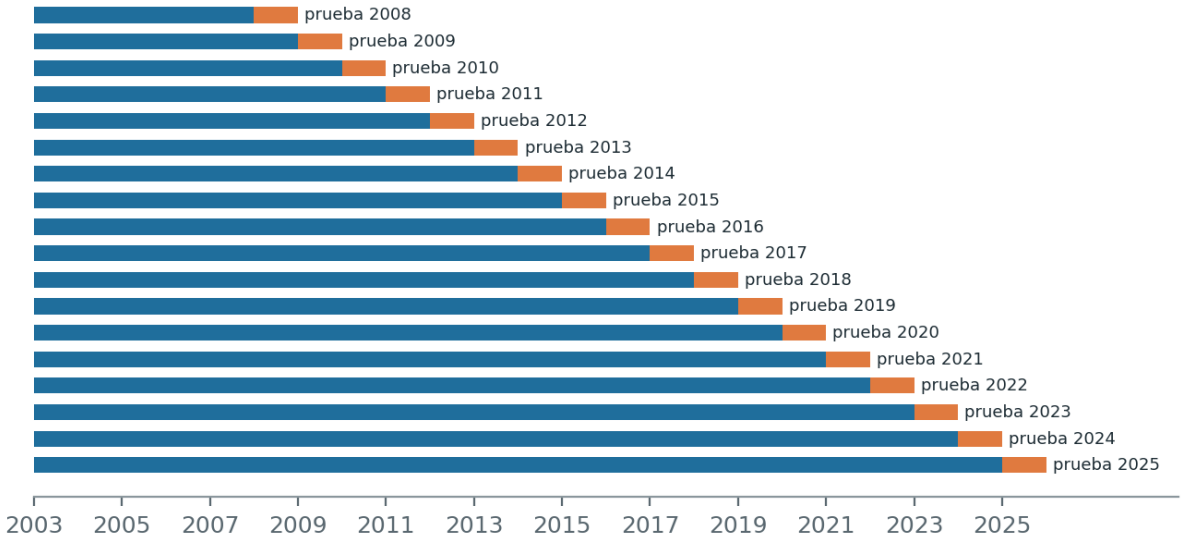
La Y ya es oficial y llega hasta 2025. Lo que más mejoraría el modelo ahora es **combinar la climatología con el clima** (en una prueba subió a PR-AUC 0,425, pero ganó solo en 7 de 18 años) y usar **lluvia más precisa** (estaciones de SENAMHI en vez de celdas de ~50 km).

PARTE 9

¿Cómo sabemos si predice?

Validación por años (origen móvil). Simulamos el uso real: entrenamos solo con años pasados y probamos en el año siguiente. Se repite para cada año de 2008 a 2025, incluidos 2017 y 2023. Además se quitan las 4 últimas semanas del entrenamiento, porque su Y mira dentro del año de prueba.

Origen móvil por años: azul = se entrena, naranja = se prueba (nunca se mira el futuro)



Esquema de la validación. El modelo nunca ve el año que está tratando de predecir.

Métrica	Qué mide en palabras simples	Un modelo al azar daría
PR-AUC (principal)	Qué tan bien encuentra los pocos casos con Y = 1 sin llenarse de falsas alarmas.	0,093
ROC-AUC	Probabilidad de que una semana con emergencia reciba más puntaje que una sin emergencia.	0,5
Brier	Promedio de $(p - y)^2$. Mide qué tan cerca está p de lo que pasó; menor es mejor.	—
Captura 5 %	De todas las emergencias, qué porcentaje cayó en el 5 % de semanas con más puntaje.	5 %

¿Predice o no? La respuesta honesta

Pregunta	Respuesta	Evidencia
¿Es mejor que el azar?	Sí, claramente.	PR-AUC 0,372 frente a 0,093 (unas 4 veces).
¿Es mejor que la climatología?	No.	La climatología logra 0,397. La logística la supera solo con 14 % de probabilidad; LightGBM empata (47 %). Bootstrap de 2 000 remuestreos por años.
¿Reconoce los años de El Niño?	Sí, ahora con datos reales.	Sin haberlos visto, 2017 y 2023 son los puestos 1 y 2 de 10 años, con PR-AUC 0,65 y 0,66.
¿Sirve para alertar una semana concreta?	Todavía no.	El 76 % de las emergencias queda fuera del 5 % de semanas más riesgosas. Captura: Piura 18 %, Tumbes 43 %.

En simple

Hoy el modelo **ordena** bien qué distritos y qué años son más riesgosos, pero **todavía no alerta** la semana exacta. Por eso en el tablero se muestra como índice de riesgo y no como alerta oficial.

PARTE 10

Limitaciones, próximos pasos y preguntas probables

Limitación	Consecuencia	Qué haremos
No supera a la climatología	La época y la historia explican casi todo.	Combinar climatología con lluvia, caudal y mar.
«Lluvia intensa» incluye daños que no son inundación	Techos y viviendas precarias se mezclan con desbordes.	Probar Y solo con inundación como sensibilidad.
SINPAD 2026 incompleto y con errores	No se usa para Y.	Incorporarlo cuando INDECI publique el año completo.
Lluvia en celdas de ~50 km	Distritos vecinos comparten el mismo valor; la lluvia pesa poco.	Usar estaciones de SENAMHI.
Subregistro en el SINPAD	Depende de lo que reporta cada municipalidad.	Revisar a mano la muestra de 20 registros.
p no está calibrada	No se puede leer como «X % de probabilidad».	Mostrar índice 0–100; probar recalibración.

Preguntas probables del profesor

¿De dónde sale Y?

Del SINPAD del INDECI, publicado en datos abiertos. Es la fuente oficial, cubre 2003–2025 y cada registro tiene código, fecha y UBIGEO. La descarga tiene huella SHA-256 y conteos por filtro.

¿Cuándo es 1 y cuándo es 0?

Y = 1 si en las 4 semanas siguientes aparece al menos un registro SINPAD de inundación o lluvia intensa para ese distrito; Y = 0 si no aparece ninguno.

¿Quién avisa cuando ya no hay emergencia?

Nadie necesita avisarlo: Y no mide si el distrito sigue en emergencia, sino si aparece un evento nuevo. Medir el estado requeriría las declaratorias de emergencia, que es otra pregunta.

¿INDECI reporta diario, semanal o mensual?

Los reportes del COEN son diarios. Nosotros agrupamos por semana porque reduce el ruido y un aviso semanal es más útil.

¿Cuántos 1 hay?

7 173 de 90 896 filas (7,9 %), que vienen de 2 431 distrito-semanas con registro (3 062 registros).

¿Por qué ya no usan DesInventar?

Termina en 2015, mezclaba marejadas y coincide con el SINPAD en solo 37 de 118 semanas. No se mezclan fuentes.

¿Por qué 4 semanas?

Es un plazo útil para preparar una respuesta y deja suficientes casos positivos para entrenar.

¿Por qué logística y no machine learning más complejo?

LightGBM, más flexible, solo empata con la climatología. La logística es estable, interpretable y ordena mejor (ROC-AUC 0,875).

¿Entonces predice?

Ordena bien los años y distritos de mayor riesgo (2017 y 2023 primeros, medidos con datos reales), pero todavía no supera a la climatología ni alerta semanas concretas. Es un índice de riesgo, no una alerta oficial.

¿Y lo de «9 de 15 distritos»?

Eso no es el modelo de predicción: es la validación de la exposición. De los 15 distritos con más afectados por inundación según INDECI, 9 están en nuestro top 15 de exposición.

Glosario rápido

Término	Significado
SINPAD	Sistema de Información Nacional para la Respuesta y Rehabilitación del INDECI: el registro oficial de emergencias.
DesInventar	Base pública de desastres que usábamos antes (fuente INDECI y prensa; termina en 2015).
COEN	Centro de Operaciones de Emergencia Nacional (INDECI).
JRC	Centro Común de Investigación de la Comisión Europea; publica mapas de zonas inundables.
GloFAS	Sistema global de alerta de inundaciones; da el caudal modelado de los ríos.
Niño 1+2	Región del océano frente a Perú y Ecuador donde se mide El Niño costero.
Estandarizar	Restar la media y dividir entre la desviación estándar.
Sobreajuste	Cuando un modelo memoriza los datos de entrenamiento y falla con datos nuevos.

Fuentes de las cifras de esta guía: INDECI, «Emergencias y daños a nivel nacional por departamento» (datosabiertos.gob.pe); data/modelo/sinpad/procedencia.json, data/modelo/base_distrito_semana.csv, data/modelo/resultados/metricas_resumen.csv, docs/evidencia/ml_evaluacion.json, docs/evidencia/auditoria_sinpad.json, dashboard/data/riesgo.json y el código src/etiqueta_sinpad.py y

src/modelo_inundacion.py (detalle en docs/10_VARIABLE_DEPENDIENTE_SINPAD.md). El ejemplo numérico de la Parte 6 se calculó con el modelo final entrenado con 2003–2025.